

Willkommen in der Arbeitsgruppe

Künstliche Intelligenz und das „Warum“

Dr. Oliver Schacht und Jan Teichert-Kluge

Sommerakademie Leysin 2026 · Studienstiftung des deutschen Volkes

Auftakt

Willkommen

Schön, dass du dabei bist 😊

Die nächsten **8 Tage** arbeiten wir in dieser Arbeitsgruppe an der Schnittstelle von **Maschinellen Lernen, Statistik** und **Kausaler Inferenz**.

Wir untersuchen nicht nur, welche Korrelationen Daten enthalten, sondern wann diese Muster etwas über **Ursache und Wirkung** aussagen.

Wir werden zunächst zusammen die Grundlagen erarbeiten und dann in Gruppenprojekten vertiefen.

Heute

#	Format	Frage
1	Ankommen & Orientierung	Wer sind wir, was ist diese AG?
2	Vorstellungsrunde	Welche Erfahrungen und Erwartungen sind im Raum?
3	Motivationsbeispiele	Wann täuscht Korrelation?
4	Gruppenarbeit & Projekte	Wie arbeiten wir in den nächsten Tagen?

Die Arbeitsgruppe

Das sind wir

Dr. Oliver Schacht



- Promotion in Statistik / **Causal Machine Learning**
- Arbeiten u.a. zum Einsatz kausaler KI in der Halbleiterfertigung
- Mitwirkung am Python-Paket **DoubleML**
- Erfahrung im Data Science Consulting bei Economic AI

Jan Teichert-Kluge



- Doktorand in Statistik / **Causal Machine Learning**
- Arbeiten u.a. zu Kausaler Inferenz mittels Deep Learning
- Mitwirkung am Python-Paket **DoubleML**
- Langjährige Industrie-Erfahrung in Data-Science-Teams

Inhalte der Arbeitsgruppe

- Die AG behandelt die Grundlagen der kausalen Inferenz (mit ML)
 - Zentrale Konzepte der kausalen Inferenz:
 - Potenzielle Outcomes und kontrafaktische Szenarien
 - Definition kausaler Effekte
 - Grafische Modelle
 - Statistische Methoden zur Untersuchung von Kausalität:
 - Randomisierte Experimente
 - Beobachtungsstudien
 - Identifikation kausaler Effekte
 - Schätzung mit ML

Lernziele der Arbeitsgruppe

- Wir wollen methodische Skills vermitteln, die in Studium, Beruf und Forschung hilfreich sein werden, z.B.,
 - wie man allgemeine Intuitionen auf eine handhabbare Weise formalisiert
 - wie man Hypothesen ableitet, die anhand von Daten getestet werden können
 - problemorientiertes und selbstorganisiertes Lernen
 - die Fähigkeit, Assoziation von Kausalität zu unterscheiden – sehr wichtig für Ihr ganzes Leben!



Gemeinsame vs. Gruppenarbeit

Gemeinsam

- Grundlagen zu ML und Kausalinferenz
- technische Unterstützung: Python, VS Code und Streamlit
- Vorstellung und Diskussion der Gruppenprojekte

In den Gruppen

- ein Vertiefungsthema eigenständig erschließen
- eine kausale Fragestellung inkl. Annahmen, Schätzung usw. beantworten
- eine kleine interaktive App oder Analyse bauen
- Annahmen, Grenzen und offene Fragen sichtbar machen

! Uns geht es nicht um eine Referatsreihe. Die Gruppenarbeiten sind ein Labor. Es geht darum mit Daten und Methodiken zu arbeiten und dabei zu lernen!

! Die abschließenden Präsentationen sind keine Prüfungen! Sie sind Anregungspunkt für Diskussionen.

Wer seid ihr?

Jeder stellt seinen Sitznachbarn vor!

1. Ihr habt 3 Minuten Zeit euren Sitznachbarn kennenzulernen
2. Wir machen eine Runde - wie viel kannst du uns über deinen Sitznachbarn erzählen?
 - z.B., Name, Studienort, Forschungsinteresse oder Fach, Fun Fact 😊

Positionsbarometer

Stellt euch gemäß eurer Position im Raum auf.

Linkes Ende

Rechtes Ende

stimme gar nicht zu

stimme voll zu

Aussagen:


1. „In meinem Studienfach ist zwischen Korrelation und Kausalitäten unterscheiden sehr wichtig.“
2. „(Trainierte) Modelle mit großen Datenmengen und vielen Parametern liefern automatisch einen guten Output.“
3. „Die Definition von Zielgröße und Annahmen ist bei datengetriebener Forschung wichtiger als die Stichprobengröße“

Warum das „Warum“ zählt

Schokolade als Nobelstrategie?

Länder mit höherem Schokoladenkonsum haben mehr Nobelpreisträger:innen pro Kopf.

i Mögliche Diagnose: Confounding. Wohlstand, Bildungs- und Forschungsinfrastruktur erhöhen plausibel sowohl den Schokoladenkonsum als auch die Chance auf wissenschaftliche Spitzenleistungen.



Attraktivität schlägt auf den Charakter?

Auf einer Dating-Plattform erhalten sehr attraktive Profile kürzere, weniger persönliche Nachrichten.

i Mögliche Diagnose: Selektions- bzw. Colliderbias.
Wer nur Menschen auf Datingapps betrachtet, konditioniert auf einen Auswahlprozess. Diese Teilmenge liefert nicht zwangsläufig valide Schlüsse auf die Population.

The Signal

2024

DATA JOURNALISM

On dating apps, the most attractive profiles get the fewest thoughtful messages

A deep-dive into one platform's match data finds a puzzling negative relationship between rated attractiveness and message quality.

Among matched pairs, better-looking profiles received shorter, less personalised opening messages.

Reconstructed teaching card (not a screenshot) — claim as circulated publicly.

Source: OkCupid OkTrends, "Your Looks and Your Inbox" (2009); cf. Bruch & Newman (2018), Science Advances. Berkson/collider framing.


gwern.net/doc/psychology/okcupid/yourlooksandyourinbox.html

KI und Geisteswissenschaftsabschlüsse

Die weltweite Verbreitung von KI und die Zahl der Geisteswissenschaftsabschlüsse verlaufen fast parallel.

i **Mögliche Diagnose: Scheinkorrelation.** Eine gemeinsame Zeitachse kann sehr unterschiedliche Größen gleichzeitig verändern. Ohne plausiblen Wirkmechanismus und Vergleichsdesign ist die fast perfekte Korrelation keine Evidenz für einen Effekt.

AI adoption tracks the number of humanities graduates almost perfectly




Der Mindestlohn macht alles teurer!!11!

Nach einer Mindestlohnerhöhung steigen auch die Preise für Brot und Brötchen.

i **Mögliche Diagnose: gemeinsame Trends und Rückkopplung.** Lebenshaltungskosten, Branchenkosten und politische Reaktionen können Löhne und Preise zugleich bewegen. Ein glaubwürdiger Vergleich könnte etwa ein **Difference-in-Differences-Design** nutzen.

Steigt der Mindestlohn, werden die Brötchen teurer

Entwicklung des Mindestlohns und der Preise in verschiedenen Branchen



info.BILD.de | Stand: April 2025

Quellen: Stat. Bundesamt, Bundesarbeitsministerium, Gesamtmittelberechnungen

Wein als heimlicher Covid Impfstoff?

In Beobachtungsdaten scheint regelmäßiger Weinkonsum mit einem niedrigeren COVID-Risiko einherzugehen.

i **Mögliche Diagnose: Confounding.** Alter, Einkommen, Gesundheit, Zugang zu Versorgung und Kontaktverhalten können sowohl den Konsum von Wein als auch das Erkrankungsrisiko beeinflussen.



BUSINESS INSIDER



Der Studie zufolge haben Menschen, die entsprechend viel Rotwein konsumierten, ein um 17 Prozentpunkte geringeres Risiko, sich mit Covid-19 zu infizieren. Und auch diejenigen, die Weißwein oder Champagner bevorzugen, dürfen sich freuen: Wer davon zwischen einem und vier Gläsern pro Woche konsumiere, habe im Vergleich zu Nichttrinkern ein um acht Prozentpunkte geringeres Risiko, sich anzustecken.

Wein ist fein, Bier lass sein

Für diejenigen, die lieber zum kühlen Blonden greifen, sind die Ergebnisse allerdings alles andere als erfreulich. Denn die Studie zeigt, dass Biertrinker im Vergleich zu Nichttrinkern ein um sieben bis 28 Prozentpunkte erhöhtes Risiko haben, sich mit Corona zu infizieren – unabhängig davon, wie viel sie konsumieren. Das gleiche gilt für Menschen, die Hochprozentiges vorziehen.

Doch was hat es auf sich mit der Schutzwirkung vom vergorenen Traubensaft? Den Forschenden zufolge weisen Weingetränke hohe Konzentrationen von Polyphenolen auf.

Krankenhausaufenthalte machen krank?

Patient:innen mit langen Krankenhausaufenthalten haben später im Mittel einen schlechteren Gesundheitszustand.

i **Mögliche Diagnose: umgekehrte Kausalität.** Häufig macht nicht der Aufenthalt krank; ein schwerer Ausgangszustand führt zugleich zu längerer Verweildauer und schlechterer späterer Gesundheit.

Klinik-Report

2024

GESUNDHEITSSYSTEM

Längere Krankenhausaufenthalte gehen mit schlechterer Gesundheit einher

Eine Auswertung von Abrechnungsdaten zeigt: Je länger die Verweildauer, desto schlechter der spätere Gesundheitszustand der Patientinnen und Patienten.

Ein Kommentator folgert, Kliniken sollten Patienten schneller entlassen, um deren Gesundheit zu schützen.

Reconstructed teaching card (not a screenshot) — claim as circulated publicly.

Source: Kanonisches Lehrbeispiel (Reverse Causation). Methode: Hernán & Robins (2020), Causal Inference: What If, Kap. 1.

<https://miguelheman.org/whatifbook>


Ausgebuchte Unterkünfte, schmerzende Augen

Regionen mit vielen ausgebuchten Airbnbs verzeichnen zugleich auffällig viele Suchanfragen nach „Augenschmerzen“.


i Mögliche Diagnose: gemeinsame Ursache. Die Sonnenfinsternis vom 8. April 2024 brachte Reisende auf ihren Verlauf und führte zugleich zu mehr Suchanfragen nach Beschwerden rund um das Beobachten der Finsternis.

Share of Airbnb and Vrbo listings booked ahead of the April 8 eclipse

Bookings on April 7, 2024, among cities with at least 50 listings



Google search volume for "eyes hurt" (April 3 to April 10, 2024)



Covid Booster und Sterblichkeitsraten

In den Gesamtdaten ist die Sterblichkeit unter den geboosterten Patient:innen höher.

i **Mögliche Diagnose: Simpsons Paradox.** Wenn Geboosterte im Schnitt deutlich älter sind, dominieren sie in den Rohdaten. Innerhalb jeder Altersgruppe kann die Sterblichkeit dennoch niedriger sein; erst die Altersstandardisierung macht den Vergleich sinnvoll.

“Most COVID deaths now are among the boosted”

Age stratum	Unvaccinated mortality rate	Boosted mortality rate
Under 50	10 / 100,000 (0.010%)	5 / 100,000 (0.005%)
50 and over	300 / 100,000 (0.300%)	150 / 100,000 (0.150%)
ALL AGES (crude)	≈ 30 / 100,000	≈ 130 / 100,000


Vom Muster zum Argument

- **Kausale Frage**
Welchen Effekt wollen wir ermitteln?
- **Counterfactual**
Was wäre sonst geschehen?
- **Design, Annahmen & Identifikation**
Warum ist der Vergleich glaubwürdig?
- **Schätzung**
Welche Schätzgröße folgt aus den Daten?
- **Interpretation**
Was zeigt sie, und was nicht?

 Ein (ML-)Modell kann eine Zahl ausgeben. Eine kausale Analyse muss zusätzlich begründen, warum diese Zahl als kausaler Effekt interpretiert werden darf.

Die nächsten Tage

Ablaufplan



- Heute setzen wir noch zusammen Python auf und erkunden Streamlit.
- Morgen gibt es interaktive Input Sessions zu ML und kausaler Inferenz
- Am 21.08. und 22.08. ist Zeit für die Gruppenarbeit
- Am 23.08. ist frei; die Präsentationen verteilen sich auf den 24. und 25.08.

Themen der Gruppenarbeit

 Randomisierte Experimente / Medizin  Explainable ML / AI  Causality and LLMs
DAGs / Causal Discovery  Causal Inference with ML  Tools: RDD / DiD  Bayesian Methods



Die Website liefert zu jedem Thema einen Einstieg, eine Demo und offene Fragen. Das Projekt beginnt nicht mit einer fertigen Antwort, sondern mit einer guten Entscheidung darüber, **was ihr zeigen wollt**.

Themengestaltung

Euer Thema setzt den Rahmen. Euer Projekt nimmt darin **eine** Frage ernst.

Nicht: „Wir erklären unser gesamtes Themengebiet.“

Sondern: „Wir untersuchen an einem klaren Beispiel, wann eine Idee oder Methode trägt, und wo ihre Grenze liegt.“

 Eine gute Forschungsfrage passt in **einen Satz**. Sie ist wissenschaftlich oder praktisch interessant, aber klein genug, um sie mit Daten, einem Experiment oder einer Simulation wirklich zu untersuchen.

Beispielhafter Projektaufbau

Baustein	Was dazu gehört
Frage & Motivation	eine präzise Forschungsfrage
Konzept & Annahmen	die zentrale Idee und was gelten muss, damit eine Aussage trägt
Setup	Daten, Replikation, Benchmark, eigenes Experiment oder Simulation
Interaktive Analyse	eine Variation, die etwas zum Vorschein bringt
Findings & Grenzen	eine Erkenntnis und ihre Limitationen

⚠ Eine Methode auszuführen oder eine Zahl zu berechnen reicht nicht. Das Ergebnis soll interaktiv sein!

Die App macht eine Idee erfahrbar

Eine statische Folie kann ein Ergebnis zeigen. In eurer App sollen andere selbst untersuchen können, was sich verändert, wenn sie zum Beispiel

- eine Annahme oder einen Parameter verändern,
- zwei Modelle oder Auswertungen vergleichen,
- eine Datenstruktur, einen Prior, Cutoff oder Prompt variieren.

Leitfrage: Was können andere durch die Interaktion verstehen, was auf einer statischen Folie unsichtbar bliebe?

Eine kleine, präzise App ist besser als ein großes Dashboard ohne klare wissenschaftliche Aussage.

Vier Arbeitsblöcke

Block	Tag	Ziel am Ende
Scope & Design	Freitag morgens	Frage, Konzept, Setup
Analyse	Freitag vormittags	Kernanalyse, erste Visualisierung
Streamlit & Story	Samstag morgens	Interaktion, Erklärung, Findings
Finalisierung	Samstag vormittags	Prototyp der App

 Erst muss das wissenschaftliche Argument funktionieren. Danach wird daraus eine gute App.

Keine Sorge

Wir sind da, um zu helfen! 😊 🙏

- Sowohl inhaltlich als auch technisch, wir arbeiten zusammen
- Es geht darum ein Verständnis von Materie und Methodik zu bekommen

Kennenlernen in den Teams

Team-Auftakt

1. **Kurz kennenlernen (falls noch nicht geschehen)**
2. **Erste Ideen austauschen**
3. **Erste Skizze festhalten:** 
 - Wir möchten verstehen: ...
 - Dafür wäre ein gutes Beispiel / Setup: ...
 - Diese Annahme oder Frage müssten wir klären: ...

 Wenn ihr schon eine Idee vorbereitet habt, nutzt die Runde zur *Diskussion*: Ist die Frage eng genug?


Abschluss

Neugierig geworden? 🔍

Quellen für entspanntes Lernen über kausales ML

Schauen: Brady Neal: *Introduction to Causal Inference*

Videoreihe mit Kursmaterialien, kurze Videos, verfügbar auf Youtube.



Hören: Causal Bandits Podcast

Vorstellung von aktuellen Forschungsthemen rund um Kausalität und Causal AI.



Lesen: *Causal Inference: The Mixtape*

Gut zugängliche Online-Einführung mit vielen anwendungsnahen Geschichten und Methoden.



Kurze Pause

Danach geht es mit dem gemeinsamen **Python-Setup** weiter.